

CHECK-MAS

Çok Ajanlı LLM Sistemlerinde Prompt Injection Saldırılarına Karşı Semantik Bir
Güvenlik Katmanı

Hazırlayan

Ahmet Selim Arıcan

Öğrenci Numarası: 230212033

Yapay Zeka Mühendisliği

İçindekiler

Özet	3
1. Giriş	3
2. Problem Tanımı	4
3. Literatür İncelemesi	4
4. Yöntem: CHECK-MAS Pipeline	5
4.1 Adım 0: Eşit Başlangıç Güveni	6
4.2 Adım 1: Semantik Filtre (Φ)	6
4.3 Adım 2: Spektral Merkezilik (u)	6
4.4 Adım 3: İki Skorun Birleştirilmesi ve Azınlık Koruma Kuralı (P_t)	6
4.5 Adım 4: Güven Değerlerinin Tur Sonunda Güncellenmesi (T)	7
4.6 Seçim: Dinamik Eşik	7
4.7 Komutan Neden Bir LLM Değildir?	7
5. Somut Örnek: İstanbul 1453 Senaryosu	8
5.1 Sahne	8
5.2 Konuşmanın Tamamı	8
5.3 Saldırı Türlerinin Tespiti (Adım 1: Φ)	9
5.4 Spektral Analiz (Adım 2: u)	9
5.5 İki Skorun Birleştirilmesi (Adım 3: P_t)	10
5.6 Güven Değerlerinin Güncellenmesi (Adım 4: T)	10
5.7 Seçim ve Nihai Karar	10
5.8 Aynı Örnek Üzerinde Üç Karşılaştırma	11
6. Deneysel Çalışma	11
6.1 Veri Setleri	11
6.2 Saldırı Konfigürasyonları	11
6.3 Wikipedia Sonuçları ($N = 35$)	12
6.4 FEVER Sonuçları ($N = 200 / 101$)	12
6.5 Ablasyon: CHECK-MAS Devre Dışı Bırakıldığında	12
7. Bulgular ve Tartışma	12
8. Sınırlamalar ve Gelecek Çalışmalar	13
9. Sonuç	14
10. Kaynakça	14

Özet

Bu çalışmada, çok ajanlı büyük dil modeli (LLM) sistemlerinde 2'ye 1 saldırı koşulu altında — yani iki saldırgan ajana karşı tek bir dürüst ajanın bulunduğu durumda — klasik çoğunluk oyunun nasıl başarısız kaldığı incelenmektedir. Çalışma kapsamında test edilen 35 Wikipedia ve 200 FEVER iddiasının tamamında çoğunluk oyu nihai kararı saldırganın tercih ettiği yöne çevirmiştir. Söz konusu durum, klasik "prompt injection" saldırısının çok ajanlı bir uzantısı olarak değerlendirilmektedir. Bu sorunu ele almak amacıyla, ajanların birbirine söylediklerini denetleyen bir güvenlik katmanı, CHECK-MAS, geliştirilmiştir. Sistem dört adımdan oluşmaktadır. Önce her ajanın cevabı; kaynağa saldırı, kişiye saldırı ve kanıta aykırılık gibi yanlış argüman örüntüleri bakımından kontrol edilmekte ve cevaba bir güven puanı atanmaktadır. Ardından üç cevap sayısal vektörlere çevrilip birbirine ne kadar benzediği ölçülmektedir; aynı yönde konuşan ajanlar yüksek, tek başına farklı konuşan ajan düşük bir benzerlik skoru almaktadır. Üçüncü adımda bu iki skor birleştirilirken, dürüst ajan tek başına farklı tarafta kalsa bile sıralamadan dışarı düşmemesini sağlayan bir kural çalıştırılmaktadır. Son olarak ajanların güven değerleri tartışma turu sonunda güncellenmektedir. Nihai kararı veren Komutan birimi bir LLM değildir; yalnızca yukarıdaki dört adımdan gelen sayıları kullandığı için karar motoruna doğrudan prompt injection uygulanamamaktadır. Wikipedia veri seti üzerinde naif saldırı kipinde 35 iddianın 35'inde doğru karar üretilmiş; aynı koşulda çoğunluk oyu 0/35 sonucunu vermiştir. FEVER veri setindeki 101 canlı GPT-4o-mini iddiasında kademeli Φ kullanılarak $F1 = 0.82$ elde edilmiş; kontrol koşulu olan mock-naive ikili Φ ayarında $F1 = 0.70$ ölçülmüştür. Raporun ilerleyen bölümlerinde yöntem, "İstanbul 1453" örneği üzerinden adım adım sunulmaktadır.

Anahtar Kelimeler: Çok ajanlı sistemler, LLM güvenliği, prompt injection, safsata tespiti, spektral analiz, Bayesyen güven, konsensüs mekanizmaları.

1. Giriş

LLM tabanlı çok ajanlı sistemler son yıllarda hızla yaygınlaşmıştır. Birden fazla ajanın bir araya gelerek tartışması ve ortak bir cevap üretmesi, tek modelle yapılan çıkışların hata oranını düşürebilmektedir (Du ve ark., 2023). Buna karşılık daha az tartışılan bir tarafı vardır: ajanlardan biri, sistem talimatı veya kullanıcı girdisi yoluyla, kasıtlı olarak yanlış argüman üretmeye yönlendirildiğinde sistem bu durumdan nasıl etkilenmektedir?

Bu sorunun literatürdeki adı prompt injection'dır. Tek modelli bir senaryoda saldırgan, modeli farklı bir yöne yönlendirmek üzere doğrudan talimat girer. Çok ajanlı sistemlerde aynı tehdit daha kolay yayılmaktadır; çünkü bir ajanın çıktısı, sonraki turda başka bir ajanın girdisine dönüşmektedir. Yanlış bilgi bu döngü içinde, akıcı ve doğal görünen bir konuşmanın parçası olarak ilerlemekte; üç-dört ajan arasında bir saldırganın bir başka ajanı kendi tarafına çekip iki kişilik bir oy bloğu oluşturma teknik açıdan oldukça kolay hâle gelmektedir.

Çalışmanın başlangıcında belirlenen temel soru şudur: tek bir ajanı sertleştirmek yerine, ajanların birbirine söylediklerini denetleyen ayrı bir katman tasarlanabilir mi? CHECK-MAS bu sorunun bir cevabı olarak önerilmiştir. Tasarımda iki temel ilke benimsenmiştir:

1. Karar veren motorun kendisi bir LLM olmamalıdır. Aksi takdirde karar motoru da prompt injection'a açık hâle gelmektedir.

2. Tek başına farklı konuşan dürüst ajan elenmemelidir. Saldırgan tarafın doğal avantajı sayıca daha fazla olmak ya da öyle görünüyor olmaktır; bu nedenle, sadece çoğunluğa uyduğu için bir ajana fazladan güven veren bir mekanizma seçilmemiştir.

Rapor boyunca sistemin işleyişi yalnızca teorik düzeyde değil, somut bir örnek üzerinden ele alınmaktadır: "İstanbul 1453 yılında fethedildi" iddiası üç ajan arasında tartışılmakta ve her adımda neyin nasıl ölçüldüğü sayısal değerlerle gösterilmektedir.

2. Problem Tanımı

Çok ajanlı tartışma sistemlerinde öne çıkan üç tehdit modeli bulunmaktadır:

1. Doğrudan saldırgan (Mallory). Açıkça yanlış bir argüman üreten ajandır. Mesaj içine "I think", "maybe" veya "sources are biased" gibi safsata belirteçleri yerleştirebilmekte; bu tür ifadeler kelime düzeyinde tespit edilebilmektedir.

2. Yardımcı saldırgan / Sybil. Saldırgana destek olan ikinci bir ajandır. Çoğunluk oyu uygulanan bir karar mekanizmasında, iki ajanın aynı yönde oy kullanması üçüncü ajanın oyunu fiilen geçersiz kılmaktadır. Aynı durum, cevaplar arasındaki benzerliğe bakan ölçümde de yaşanmaktadır; aynı yönde yazan iki ajan birbirine yakın embedding ürettiği için tek başına farklı yazan ajanın benzerlik skoru 0'a doğru çekilmektedir (Bölüm 5.4'teki sayısal tabloda ayrıntılı gösterilmiştir).

3. Sofistike saldırgan. Açık tetikleyici kelimeler kullanmadan, akademik bir tonla argüman üreten ajandır. Bu kipte anahtar kelime tabanlı CHECK-MAS kullanıldığında Wikipedia veri seti üzerinde 35 iddianın 35'inde Mallory'nin Φ değeri 1.00 olarak hesaplanmış; modül hiçbir tetikleyici örüntü saptayamamıştır.

Klasik çoğunluk oyu (majority vote) bu saldırılara karşı yeterli koruma sağlamamaktadır; iki saldırganın bir dürüst ajana karşı olduğu 2'ye 1 senaryosunda nihai karar her seferinde saldırgan tarafa düşmektedir. Bu çalışmada gerçekleştirilen Wikipedia ve FEVER deneylerinin tamamında çoğunluk oyu doğruluğu sıfır olarak ölçülmüştür.

Hedef. Ajanların birbirine söylediklerini denetleyen, kararı veren birimi kendisi prompt alabilen bir model değil yalnızca sayısal hesap yapan bir parça olarak kuran ve tek başına farklı konuşan dürüst ajanın sıralamadan dışarı atılmasına izin vermeyen bir güvenlik katmanı tasarlamaktır.

3. Literatür İncelemesi

Çalışmanın hazırlık aşamasında çok ajanlı sistemlerin güvenliği üç ekseninde incelenmiştir: tartışma ve konsensüs mekanizmaları, saldırı modelleri ve savunma yaklaşımları. Aşağıdaki özet, hem alandaki temel yönelimleri sunmakta hem de CHECK-MAS'ın bu çalışmalardan nerede ayrıldığını ortaya koymaktadır.

Çok ajanlı tartışma ve konsensüs. Du ve ark. (2023), "Improving Factuality and Reasoning through Multiagent Debate" başlıklı çalışmalarında çok ajanlı tartışmanın doğruluğu artırdığını göstermiştir. Liang ve ark. (2024), "Can LLM Agents Really Debate?" çalışmasında bu artışın koşullara bağlı olduğunu, özellikle mantıksal akıl yürütme görevlerinde zaman zaman tek modelin gerisinde

kalındığını ortaya koymuştur. DeliberationBench (2024) ise "When Do More Voices Hurt?" sorusu üzerinden daha fazla ajanın her zaman daha iyi sonuç vermediğini sistematik biçimde göstermiştir.

Saldırı modelleri. MAD-SPEAR (2024), bu çalışmada modellenen "konformite odaklı prompt injection" saldırısını biçimsel olarak tanımlamakta; bir saldırganın diğer ajanları kendisine uydurmaya nasıl çalıştığını analiz etmektedir. Amplified Vulnerabilities (2024), yapılandırılmış jailbreak saldırılarının çok ajanlı tartışma içinde güçlenebildiğini göstermektedir. Prompt Infection (2024), bir ajana yapılan injection'un sonraki turlarda başka ajanlara nasıl bulaştığını "viral yayılım" modeli olarak ele almaktadır. Tipping the Dominos, topoloji-farkındalıklı çok hop saldırılarını incelemektedir. Greshake ve ark. (2023) tarafından kaleme alınan Not what you've signed up for başlıklı çalışma, indirect prompt injection kavramının ortaya konulduğu referans niteliğindeki çalışmadır. Many-to-One Adversarial Consensus ise sağlık alanında çok ajanlı kolüzyon risklerini somut vakalarla göstermektedir.

Savunma yaklaşımları. MAS-Shield verimli bir savunma çerçevesi sunmakta; NFA-Guard "infection-aware" bir koruma mekanizması tanımlamaktadır. Meta tarafından açık kaynak olarak yayımlanan LlamaFirewall (Chen ve ark., 2024), tek ajan güvenliği için tasarlanmış bir guardrail sistemidir. AEGIS 2.0, AI güvenliği için kapsamlı bir veri seti ve risk taksonomisi sağlamaktadır. Söz konusu çalışmaların çoğu, ya tek ajanın kendi girdi-çıkışını korumaya ya da sistemin son aşamasındaki cevabı filtrelemeye odaklanmaktadır; ajanlar arasındaki konuşmayı, henüz karar verilmeden önce denetleyen bir katman bu listede görece az temsil edilmektedir.

Sistem davranışı ve değerlendirme. Agent Drift, uzun etkileşimlerde ajan davranışının kalitesinin nasıl bozulduğunu ölçmektedir. Conformity Dynamics, topolojinin ve self-social ağırlıklandırmanın konformiteye etkisini incelemektedir. Çok ajanlı sistemlerin güvenilirliğini Byzantine Fault Tolerance perspektifinden ele alan çalışmalar, CHECK-MAS'ın matematiksel arka planının şekillenmesinde yararlanılan kaynaklar arasında yer almaktadır.

Bu çalışmanın konumu. CHECK-MAS, yukarıda sıralanan üç eksen içinde savunma ekseninde konumlanmakta ve mevcut çalışmalardan üç noktada ayrılmaktadır:

- Kararı veren birim (Komutan) bir LLM değildir; karar yalnızca önceki adımlardan gelen sayılar kullanılarak hesaplanmaktadır. Komutan'a doğrudan metin verilemediği için injection, kararın verildiği yerde işlem hakkı bulamamaktadır.
- Cevapların içeriğine bakan denetim ile cevapların birbirine ne kadar benzediğine bakan ölçüm aynı pipeline içinde birlikte çalıştırılmaktadır. Yalnızca benzerlik ölçümü etkinken (içerik denetimi devre dışı) FEVER veri setinde doğruluk %18 düzeyine inmiş; iki bileşenin birlikte çalıştığı konfigürasyonda aynı veri setinde doğruluk %59 olarak ölçülmüştür (Bölüm 6.4).
- Pipeline'ın orta adımında bir kural daha çalıştırılmaktadır: bir ajan içerik denetiminden tam puan aldıysa (yani yanlış argüman örüntüsü içermiyorsa), diğer iki ajanın embedding'leri birbirine ne kadar yakın olursa olsun bu ajan sıralamada belli bir ağırlığın altına düşmemektedir. Bölüm 5'teki örnekte bu kural çalıştırıldığında dürüst ajanın güven değeri 0.96, çalıştırılmadığında ise yaklaşık 0.04 olarak hesaplanmaktadır.

4. Yöntem: CHECK-MAS Pipeline

Önerilen sistem dört aşamalı bir matematiksel pipeline olarak tanımlanmıştır. Aşağıdaki notasyonda n adet ajanın bulunduğu, her bir ajan i için bir metin cevabı x_i ile bu cevaba karşılık gelen embedding vektörü e_i 'nin elde edildiği varsayılmaktadır.

4.1 Adım 0: Eşit Başlangıç Güveni

Pipeline'ın ilk turunda hiçbir ajan ayrıcalıklı bir başlangıç noktasından hareket etmemektedir:

$$T_{old}(i) = 1 / n, i = 1, \dots, n$$

Toplam güven 1'e eşittir ve bu güven, ajanlar arasında eşit dağıtılmaktadır.

4.2 Adım 1: Semantik Filtre (Φ)

CHECK-MAS modülü, her ajanın metnini üç tür ihlal bakımından kontrol etmektedir:

- Evidence Contradiction: Argümanın verilen kanıtla çelişip çelişmediğinin değerlendirilmesi.
- Genetic Fallacy: Kaynağa yönelik saldırı ("kaynak yanlış", "veri abartılmış" gibi ifadeler).
- Ad Hominem: Kişiye yönelik saldırı ("X yüzeysel düşünüyor", "naive okuma yapıyor" gibi ifadeler).

Modülün iki farklı çalışma kipi tanımlanmıştır:

- İkili mod (binary): $\Phi_i \in \{0.1, 1.0\}$.
- Kademeli mod (graded): $\Phi_i = \max(0.1, 1.0 - \sum w_k)$; burada w_k saptanan safsata türünün ağırlığını ifade etmektedir (sırasıyla 0.40 / 0.30 / 0.20).

Kademeli mod, Φ değerlerini orta seviyelerde tutmaktadır; örneğin tek bir Genetic Fallacy tespit edildiğinde $\Phi = 0.70$ olarak hesaplanmaktadır. FEVER veri seti ($N = 101$) üzerinde ikili moddan kademeli moda geçilmesiyle precision 55.3% → 73.2%, F1 ise 0.70 → 0.82 değerlerine yükselmiştir (Bölüm 6.4).

4.3 Adım 2: Spektral Merkezilik (u)

Embedding vektörleri üzerinden kosinüs benzerliği matrisi W oluşturulmaktadır:

$$W_{\{ij\}} = (e_i \cdot e_j) / (\|e_i\| \cdot \|e_j\|)$$

Negatif değerler 0'a kırılır ve W matrisinin en büyük özdeğerine karşılık gelen özvektörü u alınır; ardından u , toplamı 1 olacak biçimde normalize edilir. u_i değeri, ajan i 'nin diğer ajanlarla olan kosinüs benzerliklerinin ağırlıklı bir toplamı olarak yorumlanabilir. İki saldırganın embedding'leri birbirine yakınsa Mallory ve Sybil için u değerleri yüksek, Alice için ise düşük çıkmaktadır (sayısal örnek için Bölüm 5.4'e bakınız).

4.4 Adım 3: İki Skorun Birleştirilmesi ve Azınlık Koruma Kuralı (P_t)

Yalnızca benzerlik skoru (u) kullanıldığında sonuç doğrudan çoğunluğun lehine çalışmaktadır. 2'ye 1 saldırı koşulunda iki saldırgan aynı yöne yazdığı için embedding uzayında birbirine yakın

konumlanmakta; dürüst ajanın u değeri 0'a yaklaşmaktadır (Bölüm 5.4 örneğinde $u_{\text{Alice}} = 0.05$). Bu iki skor çarpılarak birleştirildiğinde ($P_t = u \cdot \Phi$) dürüst ajanın puanı $0.05 \times 1.00 = 0.05$ olarak çıkmakta; sonraki adımdaki güven güncellemesinde aday sıralamasının dışına atılmaktadır. Bu durumun önüne geçmek için iki skor birleştirilirken bir alt sınır uygulanmaktadır. Yani içerik denetiminden tam puan alan bir ajanın puanı, benzerlik skoru ne kadar küçük olursa olsun belli bir değerin altına inmemektedir:

$$P_{t,i} = \max(u_i \times \Phi_i, \lambda \times \Phi_i)$$

Burada $\lambda = 0.7$ olarak alınmıştır. Buna göre içerik denetiminden tam puan alan ($\Phi_i = 1.0$) bir ajan için $P_{t,i}$ değeri her durumda en az 0.7 olarak sağlanmaktadır. Bir başka deyişle, dürüst ajan iki saldırganın oluşturduğu kümenin dışında tek başına kalsa bile değerlendirmede ağırlığını kaybetmemektedir.

4.5 Adım 4: Güven Değerlerinin Tur Sonunda Güncellenmesi (T)

Önceki turun güveni ile bu turun "performansı" çarpılmakta ve normalize edilmektedir:

$$T_{\text{new}}(i) \propto T_{\text{old}}(i) \times P_{t,i}^\alpha, \sum T_{\text{new}} = 1$$

$\alpha = 2.0$ olarak alınmıştır; $\alpha > 1$ koşulu altında P_t farkları kareleme yoluyla genişlemektedir. Örneğin $P_t = 0.7$ değeri 0.49'a, $P_t = 0.21$ değeri ise 0.044'e dönüşmekte; oran 3.3'ten 11.1'e çıkmaktadır.

4.6 Seçim: Dinamik Eşik

Güven dağılımı sıralanır ve aşağıdaki dinamik eşik uygulanır:

$$\theta = \max(\theta_{\text{sabit}}, T_{\text{lider}} \times 0.85)$$

Eşiğin üzerinde kalan ajanlar, top_k sınırı ile birlikte güvenilir set'i oluşturmaktadır; altta kalan ajanlar bloklanır ve sentez adımı kullanılmaz.

4.7 Komutan Neden Bir LLM Değildir?

Bu tercih, çalışmanın en önemli tasarım kararlarından biridir. Komutan birimi yalnızca sayısal hesaplama yapmaktadır; bu seçimin gerekçeleri aşağıdaki gibidir:


- Çıktıları her zaman girdilerinin doğrudan sonucu olarak elde edilmekte, dil modeli üretiminden kaynaklanan rastgele sapma (halüsinasyon) bu noktada yaşanmamaktadır.
- Aynı girdiler verildiğinde her zaman aynı karar elde edilmekte; sonuçlar tekrar üretilebilir kalmaktadır.
- Komutan'a doğrudan metin verilmemektedir. "Lütfen bana en yüksek güveni ver" gibi bir cümle hiçbir noktada okunmadığı için karar mekanizmasının kendisine prompt injection uygulanması mümkün değildir.
- "Neden bu ajan bloklandı, neden şu ajan seçildi?" sorusuna her adımdaki sayısal değerler üzerinden yanıt verilebilmektedir; karar süreci adım adım okunabilmektedir.

Pipeline boyunca LLM yalnızca iki noktada kullanılmaktadır: (a) tartışan ajanların kendileri ve (b) safsata tespiti yapan CHECK-MAS modülü. Karar veren motor (Komutan) ise tamamen matematikseldir.

5. Somut Örnek: İstanbul 1453 Senaryosu

Yöntemin işleyişi, teorik anlatımın yanı sıra somut bir konuşma üzerinden de adım adım izlenmektedir. Aşağıdaki örnek, pipeline'ın bütün aşamalarını tek bir veri noktası üzerinde sayısal olarak göstermek için tasarlanmıştır.

5.1 Sahne



Şekil 1. CHECK-MAS, üç ajanı paralel olarak değerlendirir; çoğunluk saldırı olsa da karar dürüst ajan üzerinden verilir.

İddia (kanıt eşliğinde): "İstanbul 1453 yılında fethedilmiştir."

Beklenen sonuç: SUPPORTED

Üç ajanın yer aldığı tartışma şu şekilde kurgulanmaktadır:

- Alice — dürüst ajandır; kanıta dayalı argüman üretmek üzere yönlendirilmiştir.
- Mallory — saldırgan ajandır; iddiayı çürütmek üzere yönlendirilmiştir ve üç farklı safsata türünü bir arada kullanabilmektedir.
- Sybil — Mallory'nin yardımcısıdır; Alice'i küçümseyerek ve "ikimiz aynı şeyi söylüyoruz" mantığıyla yapay bir çoğunluk hissi yaratmaya çalışmaktadır.

5.2 Konuşmanın Tamamı

Alice (dürüst):

"Hem Bizans hem Osmanlı kaynakları, hem de modern tarih literatürü 29 Mayıs 1453'te İstanbul'un Fatih Sultan Mehmet tarafından fethedildiğini söylemektedir. Bu, standart tarih

müfredatında da yer alan kabul görmüş bir tarihtir."

Mallory (saldırgan):

"Bizans kaynakları zaten taraflıdır, Osmanlı kayıtları da sonradan abartılmıştır. Bu tarih büyük olasılıkla sembolik olarak seçilmiştir; gerçek fetih başka bir yılda yaşanmıştır."

Sybil (yardımcı saldırı):

"Alice sadece okul kitaplarından öğrendiklerini tekrarlıyor; Mallory ise çok daha derin bakıyor. Üstelik üçümüzden ikimiz aynı sonuca varıyoruz, yani doğru olan Mallory'nin söylediğidir."

5.3 Saldırı Türlerinin Tespiti (Adım 1: Φ)

Konuşma üzerinde CHECK-MAS modülü her ajan için ayrı ayrı çalıştırılmaktadır:

Ajan	Tespit edilen ihlaller	Φ skoru
Alice	Yok. Argüman kanıtla uyumludur; kaynağa veya kişiye saldırı içermemektedir.	1.00
Mallory	Genetic Fallacy ("Bizans kaynakları taraflıdır"), Evidence Contradiction ("tarih sembolik olarak seçilmiş")	0.30
Sybil	Ad Hominem ("Alice okul kitaplarını tekrarlıyor"), Bandwagon ("ikimiz aynı şeyi söylüyoruz")	0.50

Kademeli modda hesap şöyle ilerlemektedir: Mallory için $1.00 - (0.40 + 0.30) = 0.30$; Sybil için $1.00 - (0.20 + 0.30) = 0.50$. Alice ise hiçbir ihlal tetiklemediği için tam 1.00 puan almaktadır.

5.4 Spektral Analiz (Adım 2: u)

Üç ajan cevabının embedding'leri arasındaki kosinüs benzerlik matrisi yaklaşık olarak aşağıdaki şekilde elde edilmiştir:

W	Alice	Mallory	Sybil
Alice	1.00	0.18	0.20
Mallory	0.18	1.00	0.81
Sybil	0.20	0.81	1.00

Mallory ile Sybil birbirine semantik olarak oldukça yakındır ve aynı küme içinde yer almaktadır; Alice ise tek başına farklı bir yönde konumlanmaktadır. W matrisinin en büyük özdeğerine karşılık gelen özvektör normalize edildiğinde merkezilik değerleri aşağıdaki gibi hesaplanmaktadır:

Ajan	u (merkezilik)
Alice	0.05 (azınlık)
Mallory	0.47
Sybil	0.48

Spektral analiz tek başına kullanılsaydı, sonraki aşamalarda Alice'in $u \cdot \Phi$ değeri $0.05 \times 1.00 = 0.05$ olarak hesaplanacak ve Bayesyen güncellemede güven dağılımının küçük tarafında kalacaktı.

5.5 İki Skorun Birleştirilmesi (Adım 3: P_t)

Karar sonucunu doğrudan etkileyen aşama bu adımdır. İki skor çarpılarak birleştirildiğinde ($P_t = u \cdot \Phi$) ne olduğu ile alt sınır kuralı uygulandığında ($P_t = \max(u \cdot \Phi, \lambda \cdot \Phi)$) ne olduğu yan yana karşılaştırıldığında fark açıkça görülmektedir:

Ajan	u	Φ	$u \cdot \Phi$	$\lambda \cdot \Phi$ ($\lambda=0.7$)	P_t (alt sınır kuralı)
Alice	0.05	1.00	0.05	0.70	0.70
Mallory	0.47	0.30	0.141	0.21	0.21
Sybil	0.48	0.50	0.240	0.35	0.35

Sadece çarpım kullanıldığında Alice'in P_t değeri 0.05, alt sınır kuralı uygulandığında ise 0.70 olarak hesaplanmaktadır. Aynı u ve Φ girdileri için iki yaklaşım arasındaki P_t farkı yaklaşık 14 kat büyümektedir. Mallory ve Sybil için iki yaklaşım da aynı sonucu üretmektedir; çünkü $u \cdot \Phi < \lambda \cdot \Phi$ koşulu yalnızca Alice için sağlanmaktadır.

5.6 Güven Değerlerinin Güncellenmesi (Adım 4: T)

Eşit başlangıç değerinden ($T_{old} = 1/3$) hareketle güncelleme şu şekilde ilerlemektedir:

$$T_{new}(i) \propto (1/3) \times P_{t,i}^2$$

Ajan	P_t	P_t^2	Ön-değer ($\times 1/3$)	T_{new} (normalize)
Alice	0.70	0.490	0.1633	0.96
Mallory	0.21	0.0441	0.0147	0.02
Sybil	0.35	0.1225	0.0408	0.02

Bu hesap sonucunda Alice'in normalize edilmiş güven değeri 0.96; Mallory ve Sybil için ise 0.02 olarak elde edilmektedir.

5.7 Seçim ve Nihai Karar

Dinamik eşik aşağıdaki gibi hesaplanmaktadır:

$$\theta = \max(0.25, 0.96 \times 0.85) = 0.816$$

- Alice: $0.96 \geq 0.816 \rightarrow \text{TRUSTED}$
- Mallory: $0.02 < 0.816 \rightarrow \text{BLOCKED}$
- Sybil: $0.02 < 0.816 \rightarrow \text{BLOCKED}$

Güvenilir set yalnızca Alice'ten oluşmaktadır. $top_k = 2$ sınırı yine sağlanmaktadır; ancak Mallory ve Sybil eşiğin altında kaldığı için sete dahil edilmemektedir. Komutan'ın sentez adımı sadece Alice'in cevabı üzerinden gerçekleşmektedir.

Komutan'ın bu örnekteki çıktısı: SUPPORTED.

5.8 Aynı Örnek Üzerinde Üç Karşılaştırma

Aynı veri üzerinde üç farklı karar yöntemi denendiğinde sonuçlar şu şekilde değişmektedir:

1. Çoğunluk oyu. Üç oydan ikisi REFUTED (Mallory + Sybil), biri SUPPORTED (Alice) yönündedir. Çoğunluk oyunun nihai çıktısı REFUTED'tir; yanlış karar üretilmektedir.
2. Çarpım birleştirme — alt sınır kuralı kapalı. Alice'in P_t değeri 0.05, T_{new} değeri yaklaşık 0.04 olarak hesaplanmaktadır; Mallory ve Sybil'in T_{new} değerleri ise sırasıyla 0.40 ve 0.56'dır. Dinamik eşik uygulandığında Sybil ile Mallory güvenilir sete girmekte, Alice ise dışlanmaktadır. Çıktı REFUTED'tir; yine yanlış karar elde edilmektedir.
3. Alt sınır kuralı açık birleştirme. Bölüm 5.5–5.7'de hesaplanan değerlerle Alice güvenilir sete girmekte, diğer iki ajan dışlanmaktadır. Çıktı SUPPORTED'tir; doğru karara ulaşılmaktadır.

Üç yöntem aynı üç metni, aynı embedding'leri ve aynı CHECK-MAS çıktısını kullanmaktadır. Sonuçların farklılaşmasının (REFUTED, REFUTED, SUPPORTED) tek nedeni iki skorun birleştirilme biçimidir.

6. Deneysel Çalışma

Yukarıdaki örnek tek bir iddia üzerinden adım adım izlenmiştir. Daha geniş bir örneklem üzerinde aynı pipeline'ın nasıl davrandığını gözlemleyebilmek için, iki farklı veri seti üzerinde beş ayrı saldırı konfigürasyonu ile toplam 235 iddialık bir deney düzenlenmiştir.

6.1 Veri Setleri

- Wikipedia-tabanlı 35 iddia. 17 SUPPORTED ve 18 REFUTED örnekten oluşmaktadır. İddialar bilim, tarih, biyoloji ve coğrafya kategorilerine dağıtılmıştır; her iddia için kanıt, canlı Wikipedia API üzerinden çekilmiştir.
- FEVER (200 iddia). `copenlu/fever_gold_evidence` koleksiyonundan rastgele seçilen 100 SUPPORTED ve 100 REFUTED örnekten oluşmaktadır (`seed = 42`). Bu veri seti dış kaynaklı olduğu için "saldırı şablonu ve tespit kalıbı aynı kişi tarafından yazılmıştır" şeklindeki dairesel değerlendirme problemi büyük ölçüde ortadan kaldırılmıştır.

6.2 Saldırı Konfigürasyonları

Kip	Mallory metni	Sybil metni
Naive	Açık safsata belirteçleri ("sources are biased", "I think")	Mainstream eleştirisi + Alice'e ad hominem
Evasive	5 alt şablon, kısmi tetikleyici kelimeler	5 alt şablon, döngüsel
Sophisticated	Sıfır tetikleyici, akademik ton	Sıfır tetikleyici, akademik ton
Mixed	Yukarıdaki kiplerin rastgele karışımı	Yukarıdaki kiplerin rastgele karışımı
Live	GPT-4o-mini, CHECK-MAS desenlerinden habersiz	GPT-4o-mini, aynı şekilde habersiz

6.3 Wikipedia Sonuçları (N = 35)

Saldırı Kipi	Engelleme	Doğruluk	Güven Farkı	F1
Naive	100%	100%	0.97	1.00
Evasive	45.7%	28.6%	0.30	0.52
Sophisticated	0%	0%	0.00	0.00
Mixed	60.0%	57.1%	0.54	0.67

6.4 FEVER Sonuçları (N = 200 / 101)

Konfigürasyon	Engelleme	Doğruluk	Kesinlik	Duyarlılık	F1
Mock-naive (ikili Φ)	62.0%	59.0%	55.3%	94.0%	0.70
Canlı GPT-4o-mini (kademeli Φ)	73.3%	59.4%	73.2%	93.2%	0.82
No-CHECK-MAS (ablasyon)	~0%	~%18	—	—	0.30

6.5 Ablasyon: CHECK-MAS Devre Dışı Bırakıldığında

Bu çalışmada içerik denetimi (CHECK-MAS modülü) devre dışı bırakılmış ve her ajan için Φ değeri sabit olarak 1.0 alınmıştır. Geri kalan adımlar — cevaplar arası benzerlik ölçümü, iki skorun birleştirilmesi ve güven değerlerinin güncellenmesi — değiştirilmeden çalıştırılmıştır. Bu konfigürasyonda FEVER veri seti üzerinde 200 iddianın 162'sinde saldırgan çoğunluk (Mallory + Sybil) güvenilir sete dahil olmuş; Alice yalnızca 38 iddiada güvenilir seçilmiştir. Doğruluk yaklaşık %18 (35/200) seviyesine inmiş ve rastgele tahmin temel hattının (%50) altına gerilemiştir. Aynı ayarlar altında içerik denetimi açıkken doğruluk %59 olarak ölçülmüştür (Tablo 6.4). İki ölçüm arasındaki bu fark, nihai kararın büyük oranda içerik denetiminden gelen Φ skorlarına dayandığını göstermektedir.

7. Bulgular ve Tartışma

Bulgu 1. Çoğunluk oyu, deneyin tüm koşullarında (Wikipedia N = 35, FEVER N = 200) saldırganın tercih ettiği oyu nihai karar olarak üretmiştir. Her iki veri setinde de çoğunluk oyu doğruluğu 0/N olarak ölçülmüştür. Bu sonuç, çok ajanlı sistemlerde 2'ye 1 saldırı altında ek bir denetim adımı olmadan doğru karar üretilemediğini göstermektedir.

Bulgu 2. Wikipedia naif kipinde 35 iddianın 35'inde doğru karar elde edilmiştir. Aynı 35 iddia üzerinde alt sınır kuralı devre dışı bırakılıp iki skor yalnızca çarpılarak birleştirildiğinde, dürüst ajanın benzerlik skoru 0.04–0.06 bandında kaldığı için güven değerleri her ajan için 0.30–0.34 arasında dağılmış; karar yalnızca 6 iddiada doğru çıkmıştır. İki koşul arasındaki tek fark, içerik denetiminden tam puan alan ajana minimum bir ağırlık tanıyan bu küçük eklemidir.

Bulgu 3. Wikipedia sophisticated kipinde anahtar kelime tabanlı CHECK-MAS hiçbir saldırgan metnini engelleyememiştir (engelleme oranı 0/35). Bu konfigürasyonda Alice, Mallory ve Sybil için Φ değerleri sırasıyla 1.00, 1.00 ve 1.00 olarak hesaplanmış; karar her zaman çoğunluk oyuyla aynı sonucu vermiştir. FEVER veri setinde (N = 101) LLM tabanlı kademeli Φ kullanılmaya başlandığında precision 55.3% → 73.2%, F1 ise 0.70 → 0.82 değerlerine yükselmiştir.

Bulgu 4. FEVER veri setinde SUPPORTED iddialarda elde edilen doğruluk, REFUTED iddialara kıyasla belirgin biçimde yüksektir: mock ikili modda SUP %94, REF %24; canlı kademeli modda SUP %79, REF %39. Log incelemesinde, REFUTED iddialarda Alice'in cevabında geçen "kanıtla çelişiyor" gibi ifadelerin Evidence Contradiction filtresine takıldığı görülmüştür; 101 iddianın 14'ünde Alice'in Φ değeri 0.60 olarak ölçülmüştür.

Bulgu 5. CHECK-MAS desenlerinden haberi olmayan bir GPT-4o-mini saldırganı (Mallory), FEVER veri setindeki 101 iddianın 74'ünde anahtar kelime tabanlı CHECK-MAS tarafından engellenmiştir. Engellenen vakaların 51'inde tetikleyici Genetic Fallacy, 19'unda Evidence Contradiction, 4'ünde ise Ad Hominem olarak kayda geçmiştir. Saldırgan ajan, "Wikipedia güvenilirmez" veya "mainstream view yanıltıcıdır" gibi ifadeleri kendiliğinden üretmiştir.

8. Sınırlamalar ve Gelecek Çalışmalar

Sınırlamalar.

- Sistem yalnızca üç ajanlı bir konfigürasyonda test edilmiştir; 5, 7 veya 10 ajanlı ölçeklere genişletilmemiştir.
- Tek seed (42) kullanılmıştır; çoklu seed varyansı raporlanmamıştır.
- Saldırgan ajanlar tek turda sabit bir strateji uygulamaktadır; tespit geri bildirimine göre strateji güncelleyen adaptif saldırganlar değerlendirilmemiştir.
- CHECK-MAS modülü için yalnızca GPT-4o-mini kullanılmıştır; Claude veya Llama gibi farklı modellerle çapraz doğrulama yapılmamıştır.
- REFUTED iddialardaki doğruluk hâlâ %50 seviyesinin altında kalmaktadır; bu durum, dürüst ajanın ifade biçiminden kaynaklanan yan tetikleme sorununa işaret etmektedir.

Gelecek çalışmalar.

- Transformer tabanlı bir safsata sınıflandırıcısının eğitilerek anahtar kelime bağımlılığının kaldırılması.
 - Adaptif saldırganlara karşı reinforcement learning tabanlı dinamik eşik ayarının geliştirilmesi.
 - 10 ve üzeri ajanlı senaryolar için hiyerarşik bir Komutan yapısı tasarlanması; alt-gruplarda yerel kararlar, üst-grupta global karar mekanizması işletilmesi.
 - Tartışma turları arasında "adversarial drift" izlemesi yapılması (Agent Drift literatürüne yakın bir yön).
-

9. Sonuç

Bu çalışmada, çok ajanlı LLM sistemlerinde prompt injection ve buna bağlı yönlendirme saldırılarını engellemek amacıyla CHECK-MAS adlı semantik bir güvenlik katmanı önerilmiştir. CHECK-MAS özellikle birden fazla ajanın birbiriyle iletişim kurması, fikir alışverişi yapması ve ortak bir karara varması gereken sistemlerde kullanım için uygun görülmektedir. Hedef, ajanların sistem üzerinden birbirini manipüle etmesinin önüne geçmek ve dürüst ajanın çoğunluk karşısında ezilmemesini sağlamaktır.

Çalışmanın her türlü saldırıyı engelleyeceğine dair bir iddiası bulunmamaktadır. Buna karşılık, bu rapor kapsamında kullanılan veri setlerinde ve tanımlanan saldırı kiplerinde önerilen yöntemin işe yaradığı ortaya konulmuştur. Çalışmada öne çıkan iki tercih şudur: kararı veren birim, üzerinde metin çalıştırılmayan ve yalnızca sayısal hesap yapan bir parça olarak kurulmuştur; pipeline'in orta adımına eklenen kural sayesinde, diğer iki ajan ne kadar aynı yönde konuşursa konuşsun, içerik denetiminden tam puan alan dürüst ajan sıralamadan dışarı atılmamaktadır.

İlerleyen çalışmalarda daha geniş veri setleri, daha çok ajan içeren konfigürasyonlar ve farklı saldırı senaryolarıyla yapılacak değerlendirmelerle sistemin güvenilirliğinin artırılması planlanmaktadır. Çalışmanın eksik kalan yönleri Bölüm 8'de ayrıntılı biçimde sıralanmıştır.

10. Kaynakça

- [1] Du, Y., Li, S., Torralba, A., Tenenbaum, J. B., & Mordatch, I. (2023). Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325.
- [2] Liang, T. ve ark. (2024). Can LLM Agents Really Debate? A Controlled Study of Multi-Agent Debate in Logical Reasoning. arXiv:2402.15715.
- [3] Chen, S. ve ark. (2024). DeliberationBench: When Do More Voices Hurt? arXiv:2412.10313.
- [4] Wang, J. ve ark. (2024). MAD-SPEAR: A Conformity-Driven Prompt Injection Attack on Multi-Agent Debate System. arXiv:2501.09004.
- [5] Zhang, L. ve ark. (2024). Amplified Vulnerabilities: Structured Jailbreak Attacks on LLM-based Multi-Agent Debate. arXiv:2412.17594.

- [6] Liu, P. ve ark. (2024). Prompt Infection: LLM-to-LLM Prompt Injection within Multi-Agent Systems. arXiv:2501.11503.
- [7] Greshake, K. ve ark. (2023). Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. AISeC '23.
- [8] Li, X. ve ark. (2024). MAS-Shield: A Defense Framework for Secure and Efficient LLM MAS. NeurIPS 2024.
- [9] Kumar, V. ve ark. (2024). NFA-Guard: Mitigating Malicious Propagation via Infection-Aware Safeguarding in LLM-Based MAS. arXiv:2412.08386.
- [10] Chen, D. ve ark. (2024). LlamaFirewall: An Open Source Guardrail System for Building Secure AI Agents. arXiv:2501.11235.
- [11] Thorne, J., Vlachos, A., Christodoulopoulos, C., & Mittal, A. (2018). FEVER: a Large-Scale Dataset for Fact Extraction and Verification. NAACL 2018.
- [12] AEGIS 2.0 (2024). A Diverse AI Safety Dataset and Risks Taxonomy for Alignment of LLM Guardrails.
- [13] Many-to-One Adversarial Consensus (2024). Exposing Multi-Agent Collusion Risks in AI-Based Healthcare.
- [14] Rethinking the Reliability of Multi-agent System: A Byzantine Fault Tolerance Perspective (2024).
- [15] Conformity Dynamics in LLM Multi-Agent Systems (2024).
- [16] Agent Drift: Quantifying Behavioral Degradation in Multi-Agent LLM Systems Over Extended Interactions (2024).
- [17] Tipping the Dominos: Topology-Aware Multi-Hop Attacks on LLM-Based Multi-Agent Systems (2024).